

计算方法

Liquan Mei

School of Mathematics and Statistics, Xi'an Jiaotong University

数值计算方法

学习科学与工程计算中常用的数值计算方法及其相关理论。

数值计算方法

学习科学与工程计算中常用的数值计算方法及其相关理论。

必要性 科学和技术的研究从定性前进到定量，科学计算与理论、实验三足鼎力，成为科学实践的三大手段。运用计算机进行技术是科技人员的基本技能，这要求研究掌握数值计算方法。

数值计算方法

学习科学与工程计算中常用的数值计算方法及其相关理论。

必要性 科学和技术的研究从定性前进到定量，科学计算与理论、实验三足鼎力，成为科学实践的三大手段。运用计算机进行技术是科技人员的基本技能，这要求研究掌握数值计算方法。

定量分析 工程问题 数学模型 选择计算方法 误差分析 异常解释

数值计算方法

学习科学与工程计算中常用的数值计算方法及其相关理论。

必要性 科学和技术的研究从定性前进到定量，科学计算与理论、实验三足鼎力，成为科学实践的三大手段。运用计算机进行技术是科技人员的基本技能，这要求研究掌握数值计算方法。

定量分析 工程问题 数学模型 选择计算方法 误差分析 异常解释

特点 数学抽象性 严密科学性 广泛应用性 高度技术性
是与计算机密切相连，实用性强的计算数学课程

数值计算方法

学习科学与工程计算中常用的数值计算方法及其相关理论。

必要性 科学和技术的研究从定性前进到定量，科学计算与理论、实验三足鼎力，成为科学实践的三大手段。运用计算机进行技术是科技人员的基本技能，这要求研究掌握数值计算方法。

定量分析 工程问题 数学模型 选择计算方法 误差分析 异常解释

特点 数学抽象性 严密科学性 广泛应用性 高度技术性
是与计算机密切相连，实用性强的计算数学课程

任务 数值解 数值方法 数值分析（可靠性、效率）

数值计算方法

学习科学与工程计算中常用的数值计算方法及其相关理论。

必要性 科学和技术的研究从定性前进到定量，科学计算与理论、实验三足鼎力，成为科学实践的三大手段。运用计算机进行技术是科技人员的基本技能，这要求研究掌握数值计算方法。

定量分析 工程问题 数学模型 选择计算方法 误差分析 异常解释

特点 数学抽象性 严密科学性 广泛应用性 高度技术性
是与计算机密切相连，实用性强的计算数学课程

任务 数值解 数值方法 数值分析（可靠性、效率）

重点 方法的构造和使用 工作量 收敛性 优缺点

数值计算问题的类型

- 1 离散问题如求解方程组
- 2 连续问题的离散化如数值积分、数值微分、常微分方程数值解、偏微分方程数值解
- 3 离散问题的连续化数值拟合、数据逼近

数值计算方法

课程基础 高等数学, 线性代数, 计算机语言, 数据结构

- 参考书
1. 李乃成, 梅立泉, 数值分析, 科学出版社;
 2. Alfio Quarteroni, Riccardo Sacco, Fausto Saleri. Numerical Mathematics. Springer Science Business Media, Inc. 2000.
 3. 邓建中, 刘之行. 计算方法. 西安: 西安交通大学出版社. 2001

成绩 考试成绩80%, 上机作业20%

网页

<http://cc.xjtu.edu.cn/G2S/site/preview#/home/v?currentoc=363>

<http://gr.xjtu.edu.cn/web/lqmei>

第一章绪论

要求

- 1 了解数值计算方法一般概念
- 2 了解误差的来源与分类、数据误差的影响
- 3 舍入误差对数值计算的影响
- 4 计算中应注意的原则

第一章绪论

要求

- 1 了解数值计算方法一般概念
- 2 了解误差的来源与分类、数据误差的影响
- 3 舍入误差对数值计算的影响
- 4 计算中应注意的原则

一般概念

算法 由基本运算及运算顺序的规定构成的解题步骤

第一章绪论

要求

- 1 了解数值计算方法一般概念
- 2 了解误差的来源与分类、数据误差的影响
- 3 舍入误差对数值计算的影响
- 4 计算中应注意的原则

一般概念

算法 由基本运算及运算顺序的规定构成的解题步骤

好算法 运算量少 存储小 逻辑结构简单 易编程 结果可靠

第一章绪论

要求

- 1 了解数值计算方法一般概念
- 2 了解误差的来源与分类、数据误差的影响
- 3 舍入误差对数值计算的影响
- 4 计算中应注意的原则

一般概念

算法 由基本运算及运算顺序的规定构成的解题步骤

好算法 运算量少 存储小 逻辑结构简单 易编程 结果可靠

稳定性 计算过程中误差可控，各步误差对结果不致产生过大影响

第一章绪论

要求

- 1 了解数值计算方法一般概念
- 2 了解误差的来源与分类、数据误差的影响
- 3 舍入误差对数值计算的影响
- 4 计算中应注意的原则

一般概念

算法 由基本运算及运算顺序的规定构成的解题步骤

好算法 运算量少 存储小 逻辑结构简单 易编程 结果可靠

稳定性 计算过程中误差可控，各步误差对结果不致产生过大影响

收敛性 增加计算量，近似解充分接近真解

来源与分类

- 1 模型误差: 在建立数学模型时, 忽略次要因素而造成的
- 2 观测误差、数据误差或参量误差:
- 3 截断误差或方法误差
- 4 舍入误差或计算误差: 由于计算机中的性能限制而造成的

来源与分类

- 1 模型误差: 在建立数学模型时, 忽略次要因素而造成的
- 2 观测误差、数据误差或参量误差:
- 3 截断误差或方法误差
- 4 舍入误差或计算误差: 由于计算机中的性能限制而造成的

设 x 为准确值, \tilde{x} 是 x 的一个近似值,

◇ **绝对误差** $\Delta x = x - \tilde{x}$ 或 $|\Delta x| = |x - \tilde{x}| \leq \epsilon$ $x = \tilde{x} \pm \epsilon$

来源与分类

- 1 模型误差: 在建立数学模型时, 忽略次要因素而造成的
- 2 观测误差、数据误差或参量误差:
- 3 截断误差或方法误差
- 4 舍入误差或计算误差: 由于计算机中的性能限制而造成的

设 x 为准确值, \tilde{x} 是 x 的一个近似值,

◇ **绝对误差** $\Delta x = x - \tilde{x}$ 或 $|\Delta x| = |x - \tilde{x}| \leq \epsilon$ $x = \tilde{x} \pm \epsilon$

◇ **相对误差** $\delta x = \frac{x - \tilde{x}}{x}$ 或 $|\delta x|$

[◇] **准确数字** $|x - \tilde{x}| \leq \frac{1}{2} \times 10^{-n}$, 则称近似值 \tilde{x} 准确到 n 位小数, 并将从该位起直到最左端的非零数字之间的一切数字称为近似值 \tilde{x} 的 **准确数字 (有效数字)**

[◇] **准确数字** $|x - \tilde{x}| \leq \frac{1}{2} \times 10^{-n}$, 则称近似值 \tilde{x} 准确到 n 位小数, 并将从该位起直到最左端的非零数字之间的一切数字称为近似值 \tilde{x} 的 **准确数字 (有效数字)**

如 π , 若取 π 的近似值分别为 $\pi_1 = 3.1416$, $\pi_2 = \frac{22}{7} = 3.1428\dots$

[◇] **准确数字** $|x - \tilde{x}| \leq \frac{1}{2} \times 10^{-n}$, 则称近似值 \tilde{x} 准确到 n 位小数, 并将从该位起直到最左端的非零数字之间的一切数字称为近似值 \tilde{x} 的 **准确数字 (有效数字)**

如 π , 若取 π 的近似值分别为 $\pi_1 = 3.1416$, $\pi_2 = \frac{22}{7} = 3.1428\dots$ 则

$$|\pi - \pi_1| = 0.000\,007\,3\dots < 0.000\,05 = \frac{1}{2} \times 10^{-4},$$

$$|\pi - \pi_2| = 0.0012\dots < 0.005 = \frac{1}{2} \times 10^{-2}.$$

由此可知近似值 π_1 准确到4位小数, 具有5位准确数字.

[◇] **准确数字** $|x - \tilde{x}| \leq \frac{1}{2} \times 10^{-n}$, 则称近似值 \tilde{x} 准确到 n 位小数, 并将从该位起直到最左端的非零数字之间的一切数字称为近似值 \tilde{x} 的 **准确数字 (有效数字)**

[◇]准确数字 $|x - \tilde{x}| \leq \frac{1}{2} \times 10^{-n}$, 则称近似值 \tilde{x} 准确到 n 位小数, 并将从该位起直到最左端的非零数字之间的一切数字称为近似值 \tilde{x} 的准确数字 (有效数字)

若把 x ($x_1 \neq 0$)写成标浮点形式

$$\tilde{x} = \pm x_1 x_2 \cdots x_m . x_{m+1} \cdots x_{m+n} = \pm 10^m \times 0 . x_1 x_2 \cdots x_{n+m}$$

绝对误差界为 $\frac{1}{2} \times 10^{-n}$ 时, \tilde{x} 准确到 n 位小数, 具有 $n + m$ 位准确数字.

$$\tilde{x} = \pm 0.0 \cdots 0 x_1 x_2 \cdots x_{n-m} = \pm 10^{-m} \times 0 . x_1 x_2 \cdots x_{n-m}$$

绝对误差界为 $\frac{1}{2} \times 10^{-n}$ 时, \tilde{x} 准确到 n 位小数, 具有 $n - m$ 位准确数字

习题1

1-1 已知 $\sqrt{2} = 1.414\,213\,562\,373\cdots$ ，分别写出准确到3至5位小数的近似值，指出它们的绝对误差界，相对误差界以及有效数字的位数.

解：

$$\sqrt{2} \approx \tilde{x}_1 = 1.414, \quad \sqrt{2} \approx \tilde{x}_2 = 1.414\,2,$$

$$|\sqrt{2} - 1.414| \leq \frac{1}{2} \times 10^{-3}, \quad |\sqrt{2} - 1.414\,2| \leq \frac{1}{2} \times 10^{-4},$$

$$\delta_1 = \frac{|\sqrt{2} - 1.414|}{\sqrt{2}} \leq \frac{\frac{1}{2} \times 10^{-3}}{\sqrt{2}} \approx 0.353\,553\,39 \times 10^{-3}$$

$$\delta_2 = \frac{|\sqrt{2} - 1.414\,2|}{\sqrt{2}} \leq \frac{\frac{1}{2} \times 10^{-4}}{\sqrt{2}} \approx 0.353\,553\,39 \times 10^{-4}$$

计算机中数的表示

计算机中的实数采用**浮点表示法**，即将一个数分为指数和尾数两部分来表示. 设计算机采用 β 进制

$$fl(x) = \tilde{x} = \pm \left\{ \frac{x_1}{\beta} + \frac{x_2}{\beta^2} + \cdots + \frac{x_t}{\beta^t} \right\} \times \beta^l = \pm 0.x_1x_2\cdots x_t \times \beta^l,$$

其中 $x_1 \in \{1, 2, \dots, \beta - 1\}$, $x_i \in \{0, 1, \dots, \beta - 1\}$, $i = 2, 3, \dots, t$.
指数 l 是整数, 也称为阶码. 阶码 l 的取值范围
为 $L \leq l \leq U$ ($L < 0, U > 0$).

计算机中数的表示

单精度浮点数按32位存储，双精度浮点数按64位存储。单精度浮点数的尾数为23位、阶数为8位；双精度浮点数的尾数为53位（包含符号位）、阶数为11位（包含符号位）。

计算机所能表示的全部浮点数的集合称为计算机的浮点数集，记为

$$F(\beta, t, L, U) = \{0\} \cup \{fl(x) = \pm 0.x_1x_2 \cdots x_t \times \beta^l\}.$$

浮点数集中共有 $2(\beta - 1)\beta^{t-1}(U - L + 1) + 1$ 个数，它所能表示的数的范围为

$$fl_{\min}(x) = \beta^{L-1} \leq |fl(x)| \leq \beta^U \times (1 - \beta^{-t}) = fl_{\max}(x).$$

浮点数的特点

- 实数转换到浮点数-浮点化, 〈缺点:〉会产生误差, 按四舍五入, 绝对误差. 〈优点:〉浮点化产生的相对误差有界一个实数 x 一般只能用最接近的浮点数 $fl(x)$ 替代它, 由此将产生舍入误差. 浮点数 $fl(x)$ 的绝对误差与相对误差分别为

$$|x - fl(x)| \leq \frac{1}{2}\beta^{-t} \times \beta^l = \frac{1}{2}\beta^{l-t},$$

$$\frac{|x - fl(x)|}{|x|} \leq \frac{\frac{1}{2}\beta^{l-t}}{\beta^{l-1}} = \frac{1}{2}\beta^{-(t-1)}.$$

相对误差限 $\frac{1}{2}\beta^{-(t-1)}$ 只与计算机数的进制和字长有关, 称为计算机的相对精度.

- 每一个浮点数集的数字有限
- 浮点数集中的运算非自封闭, (因为数字有限等)

- 浮点数运算结果的指数 l 不在范围 $[L,U]$ 中, 例
如: $F(2,3,-1,2)$ 中, $(0.100 * 2^2) \times (0.110 * 2^2) = 0.110 * 2^3$.
上溢
- 结果的尾数多于 t 位数字, 例
如: $F(2,3,-1,2)$ 中, $(0.100 * 2^0) + (0.111 * 2^0) = 0.1011 * 2^1$
舍入.
- 在浮点数集中数据的尾数字长 t 是有限, 当两个相近数相减时, 会损失比较多的有效数字
- 在相同的指数条件下, 两个数量相差较大的数字相加 (减) 时, 较小数的有效数字会被丧失

计算中应注意的原则

- 1 尽量避免两个相近的数相减. 常用的做法是变换算式.

例如, 当 $|x|$ 的绝对值充分大时, $\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1} + \sqrt{x}}.$

计算中应注意的原则

- 1 尽量避免两个相近的数相减. 常用的做法是变换算式.

例如, 当 $|x|$ 的绝对值充分大时, $\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1} + \sqrt{x}}$.

- 2 尽量避免绝对值很大的数作乘数, 绝对值较小的数作除数.
由绝对误差估计式可知两数乘、除运算的绝对误差分别为:

$$\Delta(x_1 x_2) \approx x_2 \Delta x_1 + x_1 \Delta x_2, \Delta\left(\frac{x_1}{x_2}\right) \approx \frac{\Delta x_1}{x_2} - \frac{x_1}{x_2^2} \Delta x_2.$$

计算中应注意的原则

- 1 尽量避免两个相近的数相减. 常用的做法是变换算式.

例如, 当 $|x|$ 的绝对值充分大时, $\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1} + \sqrt{x}}$.

- 2 尽量避免绝对值很大的数作乘数, 绝对值较小的数作除数.
由绝对误差估计式可知两数乘、除运算的绝对误差分别为:

$$\Delta(x_1 x_2) \approx x_2 \Delta x_1 + x_1 \Delta x_2, \Delta\left(\frac{x_1}{x_2}\right) \approx \frac{\Delta x_1}{x_2} - \frac{x_1}{x_2^2} \Delta x_2.$$

- 3 若个数相加, 应采取绝对值较小者先加的原则.

计算中应注意的原则

- 1 尽量避免两个相近的数相减. 常用的做法是变换算式.

例如, 当 $|x|$ 的绝对值充分大时, $\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1} + \sqrt{x}}$.

- 2 尽量避免绝对值很大的数作乘数, 绝对值较小的数作除数.
由绝对误差估计式可知两数乘、除运算的绝对误差分别为:

$$\Delta(x_1 x_2) \approx x_2 \Delta x_1 + x_1 \Delta x_2, \Delta\left(\frac{x_1}{x_2}\right) \approx \frac{\Delta x_1}{x_2} - \frac{x_1}{x_2^2} \Delta x_2.$$

- 3 若干个数的相加, 应采取绝对值较小者先加的原则.
- 4 尽量减少乘除法的运算次数.

例如计算多项式 $p_n(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n$ 的值, 若先计算各项 a_kx^k , 再逐项相加, 则需进行 $1 + 2 + 3 + \cdots + n = \frac{n(n+1)}{2}$ 次乘法和 n 次加法. 若用秦九韶算法, 将 $p_n(x)$ 改写为

$$p_n(x) = (\cdots((a_nx + a_{n-1})x + a_{n-2})x + \cdots + a_1)x + a_0.$$

则只需 n 次乘法和 n 次加法.

问题的性态

- 所计算的问题当原始数据发生小扰动时，问题的解一般也发生扰动。
- 问题的性态-问题的解对原始数据发生变化的敏感性。
- 原始数据小扰动导致问题解小扰动，称为良态问题；
- 反之，原始数据小扰动导致问题解大扰动，称为病态问题

问题的性态

- 所计算的问题当原始数据发生小扰动时，问题的解一般也发生扰动。
- 问题的性态-问题的解对原始数据发生变化的敏感性。
- 原始数据小扰动导致问题解小扰动，称为良态问题；
- 反之，原始数据小扰动导致问题解大扰动，称为病态问题

条件数 设原始数据 x ，计算结果 $f(x)$ ，扰动后的数据 \tilde{x} 计算结果 $f(\tilde{x})$ ，若问题 f 存在常数 m ，满足关系式

$$\left| \frac{f(x) - f(\tilde{x})}{f(x)} \right| \leq m \left| \frac{x - \tilde{x}}{x} \right|$$

或则称（相对误差之比的上界） m 为该问题的条件数，记作 $\text{cond}(f)$ 。

算法的数值稳定性

例如，计算积分

$$I_k = e^{-1} \int_0^1 x^k e^x dx, \quad k = 0, 1, \dots, 7.$$

算法的数值稳定性

例如，计算积分

$$I_k = e^{-1} \int_0^1 x^k e^x dx, \quad k = 0, 1, \dots, 7.$$

算法1 $I_0 = e^{-1} \int_0^1 e^x dx = 1 - \frac{1}{e}$,,

$$I_k = 1 - kI_{k-1}, \quad k = 1, 2, \dots, 7.$$

算法的数值稳定性

例如，计算积分

$$I_k = e^{-1} \int_0^1 x^k e^x dx, \quad k = 0, 1, \dots, 7.$$

算法1 $I_0 = e^{-1} \int_0^1 e^x dx = 1 - \frac{1}{e}$,,

$$I_k = 1 - k I_{k-1}, \quad k = 1, 2, \dots, 7.$$

算法2 $I_k = \int_0^1 x^k e^{-(1-x)} dx < \int_0^1 x^k dx = \frac{1}{k+1} \rightarrow 0$,
 $I_{k-1} = (1 - I_k)/k$, 取 $I_{11} = 0$.

算法的数值稳定性

例如，计算积分

$$I_k = e^{-1} \int_0^1 x^k e^x dx, \quad k = 0, 1, \dots, 7.$$

算法1 $I_0 = e^{-1} \int_0^1 e^x dx = 1 - \frac{1}{e}$,,

$$I_k = 1 - kI_{k-1}, \quad k = 1, 2, \dots, 7.$$

算法2 $I_k = \int_0^1 x^k e^{-(1-x)} dx < \int_0^1 x^k dx = \frac{1}{k+1} \rightarrow 0$,
 $I_{k-1} = (1 - I_k)/k$, 取 $I_{11} = 0$.

I_k	I_0	I_1	I_2	I_3	I_5	I_7
准确值	0.632 1	0.367 9	0.264 2	0.207 3	0.145 5	0.112 4
方法 1	0.632 1	0.367 9	0.264 2	0.207 4	0.148 0	0.216 0
方法 2	0.632 1	0.367 9	0.264 2	0.207 3	0.145 5	0.112 4

方法①中，原始步的误差，随着计算步数的增加被严重地放大

第二章解线性方程组的直接法

要求

- 1 熟练掌握高斯消去法及选列主元技术
- 2 掌握三角分解法
- 3 掌握向量范数与矩阵范数、方程组的条件数, 了解舍入误差对解的影响

第二章解线性方程组的直接法

要求

- 1 熟练掌握高斯消去法及选列主元技术
- 2 掌握三角分解法
- 3 掌握向量范数与矩阵范数、方程组的条件数, 了解舍入误差对解的影响

$Ax = b$, 系数矩阵的行列式 $|A| \neq 0$, 则方程组的解存在且唯一.
直接法:

第二章解线性方程组的直接法

要求

- 1 熟练掌握高斯消去法及选列主元技术
- 2 掌握三角分解法
- 3 掌握向量范数与矩阵范数、方程组的条件数, 了解舍入误差对解的影响

$Ax = b$, 系数矩阵的行列式 $|A| \neq 0$, 则方程组的解存在且唯一.
直接法: 在无舍入误差的假定下, 经过有限次运算就可以求得方程组的准确解.

基本原理:

第二章解线性方程组的直接法

要求

- 1 熟练掌握高斯消去法及选列主元技术
- 2 掌握三角分解法
- 3 掌握向量范数与矩阵范数、方程组的条件数, 了解舍入误差对解的影响

$Ax = b$, 系数矩阵的行列式 $|A| \neq 0$, 则方程组的解存在且唯一.
直接法: 在无舍入误差的假定下, 经过有限次运算就可以求得方程组的准确解.

基本原理: $Ax = b$ (一般) 等价变换 $Gx = d$ (结构简单)
 G : 对角阵、三角阵、结构简单阵

高斯消去法

高斯消去法首先是将方程组进行消元运算，将其化为一个等价的同解的上三角方程组，这个过程称为消元过程。然后通过求解上三角方程组得到原方程组的解，后一过程称为回代过程。

高斯消去法

高斯消去法首先是将方程组进行消元运算，将其化为一个等价的同解的上三角方程组，这个过程称为消元过程。然后通过求解上三角方程组得到原方程组的解，后一过程称为回代过程。

例2.1 用高斯消去法求解线性方程组

$$\begin{cases} x_1 + 2x_2 + x_3 = 0, \\ 2x_1 + 2x_2 + 3x_3 = 3, \\ -x_1 - 3x_2 = 2. \end{cases}$$

高斯消去法

高斯消去法首先是将方程组进行消元运算，将其化为一个等价的同解的上三角方程组，这个过程称为消元过程. 然后通过求解上三角方程组得到原方程组的解，后一过程称为回代过程.

例2.1 用高斯消去法求解线性方程组

$$\begin{cases} x_1 + 2x_2 + x_3 = 0, \\ 2x_1 + 2x_2 + 3x_3 = 3, \\ -x_1 - 3x_2 = 2. \end{cases}$$

解 消元过程:

第1步 保留第1个方程不动，将第2、3个方程中 x_1 前的系数消为零. 为此，第2、3个方程分别减去第1个方程的2、 -1 倍，得

$$\begin{aligned} x_1 + 2x_2 + x_3 &= 0, \\ -2x_2 + x_3 &= 3, \\ -x_2 + x_3 &= 2. \end{aligned}$$

第2步 保留第1、2个方程不动，将第3个方程中 x_2 前的系数消为零. 第3个方程减去第2个方程的 $\frac{1}{2}$ 倍，则得与原方程同解的上三角方程组：

$$\begin{aligned}x_1 + 2x_2 + x_3 &= 0, \\-2x_2 + x_3 &= 3, \\ \frac{1}{2}x_3 &= \frac{1}{2}.\end{aligned}$$

第2步 保留第1、2个方程不动, 将第3个方程中 x_2 前的系数消为零. 第3个方程减去第2个方程的 $\frac{1}{2}$ 倍, 则得与原方程同解的上三角方程组:

$$\begin{aligned}x_1 + 2x_2 + x_3 &= 0, \\-2x_2 + x_3 &= 3, \\ \frac{1}{2}x_3 &= \frac{1}{2}.\end{aligned}$$

回代过程:

求解以上上三角方程组. 从第3个方程组求得 $x_3 = 1$, 代入第2个方程可得 $x_2 = -1$, 再将 x_2, x_3 代入第1个方程组得 $x_1 = 1$.

高斯消去法的算法组织

为了便于高斯消去法在计算机上的实现以及减少计算机的存贮量, 在开始计算时将方程组的系数矩阵存放在二维数组 $A = (a_{ij})_{n \times n}$ 中, 方程的右端项存放在一维数组 b 中. 消去过程中, 记 $l_{ik} = a_{ik}^{(k-1)} / a_{kk}^{(k-1)}$, $a_{ij}^{(k)} = a_{ij}^{(k-1)} - l_{ik} a_{kj}^{(k-1)}$, ($i = k+1, k+2, \dots, n$, $j = k+1, k+2, \dots, n$). 消元过程结束后, 二维数组 A 和一维数组 b 的内容如下:

$$A = \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & a_{13}^{(0)} & \cdots & a_{1,n-1}^{(0)} & a_{1n}^{(0)} \\ l_{21} & a_{22}^{(1)} & a_{23}^{(1)} & \cdots & a_{2,n-1}^{(1)} & a_{2n}^{(1)} \\ l_{31} & l_{32} & a_{33}^{(2)} & \cdots & a_{3,n-1}^{(2)} & a_{3n}^{(2)} \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ l_{n1} & l_{n2} & l_{n3} & \cdots & l_{n,n-1} & a_{nn}^{(n-1)} \end{pmatrix}, \quad b = \begin{pmatrix} b_1^{(0)} \\ b_2^{(1)} \\ b_3^{(2)} \\ \cdots \\ b_n^{(n-1)} \end{pmatrix}.$$

高斯消去法的算法组织

高斯消去法的计算过程

消去

```
for  $k = 1$  to  $n - 1$  do
  if  $|a_{kk}| \leq \epsilon$ , then stop
  for  $i = k + 1$  to  $n$  do
     $a_{ik} := a_{ik} / a_{kk}$ 
    for  $j = k + 1$  to  $n$  do
       $a_{ij} := a_{ij} - a_{ik} a_{kj}$ 
    end do
     $b_i := b_i - a_{ik} b_k$ 
  end do
end do
```


高斯消去法的算法组织

高斯消去法的计算过程

消去

```
for  $k = 1$  to  $n - 1$  do
  if  $|a_{kk}| \leq \epsilon$ , then stop
  for  $i = k + 1$  to  $n$  do
     $a_{ik} := a_{ik} / a_{kk}$ 
    for  $j = k + 1$  to  $n$  do
       $a_{ij} := a_{ij} - a_{ik} a_{kj}$ 
    end do
     $b_i := b_i - a_{ik} b_k$ 
  end do
end do
```

回代过程

```
 $x_n := b_n / a_{nn}$ 
for  $k = n - 1$  to  $1$  do
   $s := b_k$ 
  for  $j = k + 1$  to  $n$  do
     $s := s - a_{kj} x_j$ 
  end do
   $x_k := s / a_{kk}$ 
end do
```

高斯消去法中乘除法的运算量

消元过程共进行 $n-1$ 步, 即 $k=1, 2, \dots, n-1$.

则消元过程中乘除法的运算量为

$$N_1 = \sum_{k=1}^{n-1} [(n-k)^2 + 2(n-k)] = \frac{n^3}{3} + \frac{n^2}{2} - \frac{5n}{6}.$$

回代过程乘除法的运算量为

$$N_2 = \sum_{k=1}^{n-1} (n-k) + n = \frac{n^2}{2} + \frac{n}{2}.$$

所以, 用高斯消去法解 n 阶线性方程组的乘法运算量为

$$N = N_1 + N_2 = \frac{n^3}{3} + \frac{n^2}{2} - \frac{5}{6}n + \frac{n^2}{2} + \frac{n}{2} = \frac{1}{3}n^3 + n^2 - \frac{1}{3}n.$$

高斯消去法顺利进行的条件

从消元过程知, 当且仅当 $a_{kk}^{(k-1)} \neq 0$ ($k = 1, 2, \dots, n$) 时, 高斯消去法才能进行下去.

高斯消去法能顺利进行的几个条件分别是:

高斯消去法顺利进行的条件

从消元过程知, 当且仅当 $a_{kk}^{(k-1)} \neq 0$ ($k = 1, 2, \dots, n$) 时, 高斯消去法才能进行下去.

高斯消去法能顺利进行的几个条件分别是:

条件1 系数矩阵 A 的各阶顺序主子式均不等于零.

$$D_1 = a_{11} \neq 0, \quad D_k = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{vmatrix} \neq 0, \quad k = 2, \dots, n.$$

高斯消去法顺利进行的条件

从消元过程知, 当且仅当 $a_{kk}^{(k-1)} \neq 0$ ($k = 1, 2, \dots, n$) 时, 高斯消去法才能进行下去.

高斯消去法能顺利进行的几个条件分别是:

条件1 系数矩阵 A 的各阶顺序主子式均不等于零.

$$D_1 = a_{11} \neq 0, \quad D_k = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{vmatrix} \neq 0, \quad k = 2, \dots, n.$$

条件2 系数矩阵 A 是对称正定矩阵.

高斯消去法顺利进行的条件

从消元过程知, 当且仅当 $a_{kk}^{(k-1)} \neq 0$ ($k = 1, 2, \dots, n$) 时, 高斯消去法才能进行下去.

高斯消去法能顺利进行的几个条件分别是:

条件1 系数矩阵 A 的各阶顺序主子式均不等于零.

$$D_1 = a_{11} \neq 0, \quad D_k = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{vmatrix} \neq 0, \quad k = 2, \dots, n.$$

条件2 系数矩阵 A 是对称正定矩阵.

条件3 系数矩阵 A 是严格对角占优阵.

$$\sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| < |a_{ii}|, \quad i = 1, 2, \dots, n.$$

列主元高斯消去法

在高斯消去法的消元过程中要求主元 $a_{kk}^{(k-1)} \neq 0$.

列主元高斯消去法:

在第 k 步消元之前, 从 $A^{(k-1)}$ 的第 k 列元素 $a_{kk}^{(k-1)}, \dots, a_{nk}^{(k-1)}$ 中选取绝对值最大的元 $a_{pk}^{(k-1)}$, 交换交换第 p 个方程与第 k 个方程的位置, 使新的 $a_{kk}^{(k-1)}$ 的绝对值最大, 然后进行第 k 步消元.

选主元素

$$\left\{ \begin{array}{l} max := 0.0 \\ \text{for } i = k \text{ to } n \text{ do} \\ \quad \text{if } |a_{ik}| \leq |max| \text{ then} \\ \qquad \text{go to 标号10} \\ \quad \text{else } max := a_{ik} \\ \quad q := i \\ \text{标号10 } \text{end do} \end{array} \right.$$

列主元高斯消去法

在高斯消去法的消元过程中要求主元 $a_{kk}^{(k-1)} \neq 0$.

列主元高斯消去法:

在第 k 步消元之前, 从 $A^{(k-1)}$ 的第 k 列元素 $a_{kk}^{(k-1)}, \dots, a_{nk}^{(k-1)}$ 中选取绝对值最大的元 $a_{pk}^{(k-1)}$, 交换交换第 p 个方程与第 k 个方程的位置, 使新的 $a_{kk}^{(k-1)}$ 的绝对值最大, 然后进行第 k 步消元.

选主元素 $\left\{ \begin{array}{l} \max := 0.0 \\ \text{for } i = k \text{ to } n \text{ do} \\ \quad \text{if } |a_{ik}| \leq |\max| \text{ then} \\ \qquad \text{go to 标号10} \\ \quad \text{else } \max := a_{ik} \\ \quad q := i \\ \text{标号10 end do} \end{array} \right.$

if $|\max| \leq \epsilon$, then stop
if $q = k$ then go to 消元部分

列主元高斯消去法

在高斯消去法的消元过程中要求主元 $a_{kk}^{(k-1)} \neq 0$.

列主元高斯消去法:

在第 k 步消元之前, 从 $A^{(k-1)}$ 的第 k 列元素 $a_{kk}^{(k-1)}, \dots, a_{nk}^{(k-1)}$ 中选取绝对值最大的元 $a_{pk}^{(k-1)}$, 交换交换第 p 个方程与第 k 个方程的位置, 使新的 $a_{kk}^{(k-1)}$ 的绝对值最大, 然后进行第 k 步消元.

选主元素	$\left\{ \begin{array}{l} \text{max} := 0.0 \\ \text{for } i = k \text{ to } n \text{ do} \\ \quad \text{if } a_{ik} \leq \text{max} \text{ then} \\ \qquad \text{go to 标号10} \\ \quad \text{else } \text{max} := a_{ik} \\ \quad q := i \\ \text{标号10 } \text{end do} \end{array} \right.$	交换方程位置	$\left\{ \begin{array}{l} \text{for } j = k \text{ to } n \text{ do} \\ \quad c := a_{kj} \\ \quad a_{kj} := a_{qj} \\ \quad a_{qj} := c \\ \text{end do} \\ c := b_k \\ b_k := b_q \\ b_q := c \end{array} \right.$
------	---	--------	--

if $|\text{max}| \leq \epsilon$, then stop
if $q = k$ then go to 消元部分

列主元高斯消去法

例 用列主元素高斯消去法解
方程组

$$\begin{cases} x_1 + 2x_2 + x_3 = 0, \\ 2x_1 + 2x_2 + 3x_3 = 3, \\ -x_1 - 3x_2 = 2. \end{cases}$$

列主元高斯消去法

例 用列主元素高斯消去法解方程组

$$\begin{cases} x_1 + 2x_2 + x_3 = 0, \\ 2x_1 + 2x_2 + 3x_3 = 3, \\ -x_1 - 3x_2 = 2. \end{cases}$$

置, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, & (1) \\ x_1 + 2x_2 + x_3 = 0, & (2) \\ -x_1 - 3x_2 = 2. & (3) \end{cases}$$

解 消元过程

第1步

在系数矩阵 A 的第1列元素中选取绝对值最大的元 $a_{21} = 2$, 交换第1个方程与第2个方程的位

列主元高斯消去法

例 用列主元素高斯消去法解方程组

$$\begin{cases} x_1 + 2x_2 + x_3 = 0, \\ 2x_1 + 2x_2 + 3x_3 = 3, \\ -x_1 - 3x_2 = 2. \end{cases}$$

解 消元过程

第1步

在系数矩阵 A 的第1列元素中选取绝对值最大的元 $a_{21} = 2$, 交换第1个方程与第2个方程的位

置, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, & (1) \\ x_1 + 2x_2 + x_3 = 0, & (2) \\ -x_1 - 3x_2 = 2. & (3) \end{cases}$$

进行第1步消元, 方程(2)-方程(1) $\times \frac{1}{2}$, 方程(3)-方程(1) $\times (-\frac{1}{2})$, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, & (1') \\ x_2 - \frac{1}{2}x_3 = -\frac{3}{2}, & (2') \\ -2x_2 + \frac{3}{2}x_3 = \frac{7}{2}. & (3') \end{cases}$$

第2步

在第1步消元后的矩阵 $A^{(1)}$ 的元素 $a_{22}^{(1)} = 1$, $a_{32}^{(1)} = -2$ 中选取绝对值最大的元 $a_{32}^{(1)} = -2$ 作为主元素, 交换第2个方程与第3个方程的位置, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, & (1'') \\ -2x_2 + \frac{3}{2}x_3 = \frac{7}{2}, & (2'') \\ x_2 - \frac{1}{2}x_3 = -\frac{3}{2}. & (3'') \end{cases}$$

第2步

在第1步消元后的矩阵 $A^{(1)}$ 的元素 $a_{22}^{(1)} = 1$, $a_{32}^{(1)} = -2$ 中选取绝对值最大的元 $a_{32}^{(1)} = -2$ 作为主元素, 交换第2个方程与第3个方程的位置, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, & (1'') \\ -2x_2 + \frac{3}{2}x_3 = \frac{7}{2}, & (2'') \\ x_2 - \frac{1}{2}x_3 = -\frac{3}{2}. & (3'') \end{cases}$$

进行第2步消元,

方程 $(3'') - \text{方程}(2'') \times (-\frac{1}{2})$, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, \\ -2x_2 + \frac{3}{2}x_3 = \frac{7}{2}, \\ \frac{1}{4}x_3 = \frac{1}{4}. \end{cases}$$

第2步

在第1步消元后的矩阵 $A^{(1)}$ 的元素 $a_{22}^{(1)} = 1$, $a_{32}^{(1)} = -2$ 中选取绝对值最大的元 $a_{32}^{(1)} = -2$ 作为主元素, 交换第2个方程与第3个方程的位置, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, & (1'') \\ -2x_2 + \frac{3}{2}x_3 = \frac{7}{2}, & (2'') \\ x_2 - \frac{1}{2}x_3 = -\frac{3}{2}. & (3'') \end{cases}$$

进行第2步消元,

方程 $(3'') - \text{方程}(2'') \times (-\frac{1}{2})$, 得

$$\begin{cases} 2x_1 + 2x_2 + 3x_3 = 3, \\ -2x_2 + \frac{3}{2}x_3 = \frac{7}{2}, \\ \frac{1}{4}x_3 = \frac{1}{4}. \end{cases}$$

由回代过程求得原方程组的解 $x = (1, -1, 1)^T$.

矩阵的三角分解

在实际问题中，经常遇到系数矩阵 A 相同，但右端项不同的多个线性方程组 $Ax = b^{(i)} (i = 1, 2, \dots, m)$. 矩阵的三角分解法.

矩阵的三角分解

在实际问题中，经常遇到系数矩阵 A 相同，但右端项不同的多个线性方程组 $Ax = b^{(i)}$ ($i = 1, 2, \dots, m$). 矩阵的三角分解法.

从矩阵运算的观点看高斯消去法的消元过程实质上是将增广矩阵 $(A^{(0)}, b^{(0)})$ 通过逐步左乘一系列的初等下三角矩阵 L_k ($k = 1, \dots, n-1$), 最终变为矩阵 $(A^{(n-1)}, b^{(n-1)})$, 即将原方程组化为一个同解的上三角方程组 $A^{(n-1)}x = b^{(n-1)}$.

矩阵的三角分解

在实际问题中，经常遇到系数矩阵 A 相同，但右端项不同的多个线性方程组 $Ax = b^{(i)}$ ($i = 1, 2, \dots, m$)。矩阵的三角分解法。

从矩阵运算的观点看高斯消去法的消元过程实质上是将增广矩阵 $(A^{(0)}, b^{(0)})$ 通过逐步左乘一系列的初等下三角矩阵 L_k ($k = 1, \dots, n-1$)，最终变为矩阵 $(A^{(n-1)}, b^{(n-1)})$ ，即将原方程组化为一个同解的上三角方程组 $A^{(n-1)}x = b^{(n-1)}$ 。

事实上 $A^{(0)} \triangleq A$,

$$A^{(1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1n}^{(0)} \\ 0 & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{n2}^{(1)} & \cdots & a_{nn}^{(1)} \end{pmatrix}, \quad L_1 \triangleq \begin{pmatrix} 1 & & & \\ -l_{21} & 1 & & \\ -l_{31} & & \ddots & \\ \vdots & & & \ddots \\ -l_{n1} & & & & 1 \end{pmatrix},$$

则 $A^{(1)} = L_1 A^{(0)}$ 。

高斯消去法的矩阵形式

一般地,

$$A^{(k-1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & \cdots & a_{2n}^{(1)} \\ & & \ddots & & \vdots \\ & & & a_{kk}^{(k-1)} & \cdots & a_{kn}^{(k-1)} \\ & & & \vdots & & \vdots \\ & & & a_{nk}^{(k-1)} & \cdots & a_{nn}^{(k-1)} \end{pmatrix} L_k \triangleq \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{k+1,k} & 1 & \\ & & -l_{k+2,k} & & 1 \\ & & \vdots & & \\ & & -l_{nk} & & & 1 \end{pmatrix}$$

$$A^{(k)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1,k+1} & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & a_{2,k+1} & \cdots & a_{2n}^{(1)} \\ & & \ddots & \vdots & & \vdots \\ & & & a_{kk}^{(k-1)} & \cdots & a_{kn}^{(k-1)} \\ & & & a_{k,k+1}^{(k)} & \cdots & a_{k,n}^{(k)} \\ & & & a_{k+1,k+1}^{(k)} & \cdots & a_{k+1,n}^{(k)} \\ & & & \vdots & & \vdots \\ & & & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}.$$

则有 $A^{(k)} = L_k A^{(k-1)} = L_k L_{k-1} \cdots L_2 L_1 A^{(0)}.$

高斯消去法的矩阵形式

一般地,

$$A^{(k-1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & \cdots & a_{2n}^{(1)} \\ & & \ddots & & \vdots \\ & & & a_{kk}^{(k-1)} & \cdots & a_{kn}^{(k-1)} \\ & & & \vdots & \ddots & \vdots \\ & & & a_{nk}^{(k-1)} & \cdots & a_{nn}^{(k-1)} \end{pmatrix} L_k \triangleq \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{k+1,k} & 1 & \\ & & -l_{k+2,k} & & 1 \\ & & \vdots & & \\ & & -l_{nk} & & \\ & & & \ddots & \\ & & & & 1 \end{pmatrix}$$

$$A^{(k)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1,k+1} & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & a_{2,k+1} & \cdots & a_{2n}^{(1)} \\ & & \ddots & \vdots & \ddots & \vdots \\ & & & a_{kk}^{(k-1)} & \cdots & a_{kn}^{(k-1)} \\ & & & a_{k,k+1}^{(k)} & \cdots & a_{k,n}^{(k)} \\ & & & a_{k+1,k+1}^{(k)} & \cdots & a_{k+1,n}^{(k)} \\ & & & \vdots & \ddots & \vdots \\ & & & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}.$$

则有 $A^{(k)} = L_k A^{(k-1)} = L_k L_{k-1} \cdots L_2 L_1 A^{(0)}$.

由于消元过程进行了 $n-1$ 步, 故

$$A^{(n-1)} = L_{n-1} A^{(n-2)} = \cdots = L_{n-1} L_{n-2} \cdots L_2 L_1 A^{(0)}$$

高斯消去法的矩阵形式

$$A^{(n-1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} \\ & & \ddots & \vdots \\ & & & a_{nn}^{(n-1)} \end{pmatrix}$$

同理 $b^{(n-1)} = L_{n-1}L_{n-2}\cdots L_2L_1b^{(0)}$.

注意到矩阵 L_k 的逆矩阵为

$$L_k^{-1} \triangleq \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & l_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & l_{nk} & & & 1 \end{pmatrix}$$

高斯消去法的矩阵形式

$$A^{(n-1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} \\ & & \ddots & \vdots \\ & & & a_{nn}^{(n-1)} \end{pmatrix}$$

同理 $b^{(n-1)} = L_{n-1}L_{n-2}\cdots L_2L_1b^{(0)}$.

注意到矩阵 L_k 的逆矩阵为

$$L_k^{-1} \triangleq \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & l_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & l_{nk} & & & 1 \end{pmatrix}$$

则

$$\text{有 } A = A^{(0)} = L_1^{-1}L_2^{-1}\cdots L_{n-1}^{-1}A^{(n-1)} = LU,$$

$$b = b^{(0)} = Lb^{(n-1)}.$$

其中

$$L = \begin{pmatrix} 1 & & & & \\ l_{21} & 1 & & & \\ l_{31} & l_{32} & 1 & & \\ \vdots & \vdots & \vdots & \ddots & \\ l_{n1} & l_{n2} & \cdots & l_{n,n-1} & 1 \end{pmatrix}.$$

$$U \triangleq A^{(n-1)} = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ & u_{22} & \cdots & u_{2n} \\ & & \ddots & \\ & & & u_{nn} \end{pmatrix}.$$

矩阵的 LU 分解

Theorem

设 A 为 n 阶矩阵, 如果 A 的顺序主子式 $D_k \neq 0$ ($k = 1, 2, \dots, n$), 则 A 可以唯一的分解成一个单位下三角矩阵 L 与一个上三角矩阵 U 的乘积, 即 $A = LU$.

矩阵的LU分解

Theorem

设 A 为 n 阶矩阵, 如果 A 的顺序主子式 $D_k \neq 0$ ($k = 1, 2, \dots, n$), 则 A 可以唯一的分解成一个单位下三角矩阵 L 与一个上三角矩阵 U 的乘积, 即 $A = LU$.

证明 由高斯消去法的矩阵形式可知, $A = LU$ 分解的存在性. 下面证明分解的唯一性. 设矩阵 A 有两种分解

$$A = LU = L_1 U_1.$$

其中 L, L_1 是单位下三角阵, U, U_1 是上三角阵. 由 A 可逆知 L 与 U 均可逆, 故有 $L_1^{-1}L = U_1U^{-1}$. 该式左端为单位下三角阵, 右端为上三角阵. 因此该式左右两端必是单位阵. 于是 $L_1 = L, U_1 = U$. $A = LU$ 称为矩阵 A 的LU分解.

矩阵的LU分解

$A = LU$ 分解公式如下:


$$\begin{cases} u_{1j} = a_{1j}, & j = 1, 2, \dots, n. \\ l_{i1} = a_{i1}/u_{11}, & i = 2, 3, \dots, n. \\ u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik}u_{kj}, & i = 2, 3, \dots, n, \quad j = i, i+1, \dots, n. \\ l_{ij} = (a_{ij} - \sum_{k=1}^{j-1} l_{ik}u_{kj})/u_{jj}, & j = 2, 3, \dots, n-1, \quad i = j+1, j+2, \dots, n. \end{cases}$$

矩阵的LU分解

$A = LU$ 分解公式如下:

$$\begin{cases} u_{1j} = a_{1j}, & j = 1, 2, \dots, n. \\ l_{i1} = a_{i1}/u_{11}, & i = 2, 3, \dots, n. \\ u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik}u_{kj}, & i = 2, 3, \dots, n, \quad j = i, i+1, \dots, n. \\ l_{ij} = (a_{ij} - \sum_{k=1}^{j-1} l_{ik}u_{kj})/u_{jj}, & j = 2, 3, \dots, n-1, \quad i = j+1, j+2, \dots, n. \end{cases}$$

按先算矩阵 U 的第 i 行，再算矩阵 L 的第 i 列的顺序计算，计算流程按下图所示逐框进行。



矩阵的LU分解

矩阵 $A = LU$ 分解的计算过程如下：

```

$$u_{1j} = a_{1j}, \quad j = 1, 2, \dots, n.$$

$$l_{i1} = a_{i1}/a_{11}, \quad i = 2, 3, \dots, n.$$

$$\text{for } i = 2 \text{ to } n - 1 \text{ do}$$

$$u_{ii} := a_{ii} - \sum_{k=1}^{i-1} l_{ik} u_{ki}$$

$$\text{for } j = i + 1 \text{ to } n \text{ do}$$

$$u_{ij} := a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}$$

$$l_{ji} := (a_{ji} - \sum_{k=1}^{i-1} l_{jk} u_{ki}) / u_{ii}$$

$$\text{end do}$$

$$\text{end do}$$

$$u_{nn} := a_{nn} - \sum_{k=1}^{n-1} l_{nk} u_{kn}$$

```

矩阵的 LU 分解

在计算机上实现矩阵 $A = LU$ 分解时，为了减少存储量，将 L 的下三角部分的元素存放在 A 的下三角部分相应的位置上。（ L 的对角元均等于1不用存储）。将矩阵 U 的元素存放于 A 的上三角部分位置，其编程时只需要将上述分解过程中 l_{ij}, u_{ij} 改为相应的 a_{ij} 即可。

矩阵的 LU 分解

在计算机上实现矩阵 $A = LU$ 分解时，为了减少存储量，将 L 的下三角部分的元素存放在 A 的下三角部分相应的位置上。（ L 的对角元均等于1不用存储）。将矩阵 U 的元素存放于 A 的上三角部分位置，其编程时只需要将上述分解过程中 l_{ij}, u_{ij} 改为相应的 a_{ij} 即可。

上面介绍的将矩阵分解为单位下三角阵 L 与上三角阵 U 的乘积 $A = LU$ ，称为**杜里特尔(Doolittle)分解**。同理矩阵 A 也可分解成下三角矩阵 L 与单位上三角矩阵 U 之积。这种分解称为**克洛特(Crout)分解**。

矩阵的 LU 分解

例 分解矩阵 $A = LU$, 其中

$$A = \begin{pmatrix} 4 & -2 & 0 & 4 \\ -2 & 2 & -3 & 1 \\ 0 & -3 & 13 & -7 \\ 4 & 1 & -7 & 23 \end{pmatrix}.$$

矩阵的LU分解

例 分解矩阵 $A = LU$, 其中

$$A = \begin{pmatrix} 4 & -2 & 0 & 4 \\ -2 & 2 & -3 & 1 \\ 0 & -3 & 13 & -7 \\ 4 & 1 & -7 & 23 \end{pmatrix}.$$

解 按计算公式得

$$A = LU = \begin{pmatrix} 1 & 0 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 & 0 \\ 0 & -3 & 1 & 0 \\ 1 & 3 & \frac{1}{2} & 1 \end{pmatrix} \begin{pmatrix} 4 & -2 & 0 & 4 \\ 0 & 1 & -3 & 3 \\ 0 & 0 & 4 & 2 \\ 0 & 0 & 0 & 9 \end{pmatrix}.$$

矩阵的LU分解

下面介绍利用矩阵 $A = LU$ 分解求解线性方程组 $Ax = b$.

$Ax = LUx = b$ 等价于下面两个三角方程组

$$Ly = b, \quad Ux = y.$$

先从 $Ly = b$ 解出 y , 再从 $Ux = y$ 解出 x .

解方程组 $Ly = b$. $Ly = b$ 的第一个方程为 $y_1 = b_1$, $Ly = b$ 的第 i 个方程为

$$\sum_{j=1}^{i-1} l_{ij}y_j + y_i = b_i, \quad i = 2, 3, \dots, n.$$

所以,

$$\begin{cases} y_1 = b_1, \\ y_i = b_i - \sum_{j=1}^{i-1} l_{ij}y_j, \quad i = 2, 3, \dots, n. \end{cases}$$

矩阵的 LU 分解

从 y 的计算公式可以看到，可不必先将 A 分解后再求解 $Ly = b$. 计算 y 与 A 的分解可以同时进行，具体做法是对 A 的增广矩阵 $\bar{A} = (A, b)$ 进行 LU 分解，分解结束后， \bar{A} 的第 $n + 1$ 列位置上的元即是 y 的元.

矩阵的LU分解

从 y 的计算公式可以看到，可不必先将 A 分解后再求解 $Ly = b$. 计算 y 与 A 的分解可以同时进行，具体做法是对 A 的增广矩阵 $\bar{A} = (A, b)$ 进行LU分解，分解结束后， \bar{A} 的第 $n+1$ 列位置上的元即是 y 的元.

求得 y 后，再求解上三角方程组 $Ux = y$ ，同高斯消去法的回代过程，可得

$$\begin{cases} x_n = y_n / u_{nn}, \\ x_i = (y_i - \sum_{j=i+1}^n u_{ij}x_j) / u_{ii}, \quad i = n-1, n-2, \dots, 2, 1. \end{cases}$$

用 $A = LU$ 分解解方程 $Ax = b$ 乘除法的运算量与高斯消去法的乘法运算次数相同.

矩阵的LU分解

例 2.4 用 $A = LU$ 分解求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 9 & 18 & 9 & -27 \\ 18 & 45 & 0 & -45 \\ 9 & 0 & 126 & 9 \\ -27 & -45 & 9 & 135 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

矩阵的LU分解

例 2.4 用 $A = LU$ 分解求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 9 & 18 & 9 & -27 \\ 18 & 45 & 0 & -45 \\ 9 & 0 & 126 & 9 \\ -27 & -45 & 9 & 135 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

解 将向量 b 作为 \bar{A} 的第5列, 按紧凑格式计算, 得

$$\begin{array}{cccc|c} 9 & 18 & 9 & -27 & 1 \\ 2 & \begin{array}{|c|} \hline 9 \\ \hline \end{array} & -18 & 9 & 0 \\ 1 & -2 & \begin{array}{|c|} \hline 81 \\ \hline \end{array} & 54 & 15 \\ -3 & 1 & \frac{2}{3} & \begin{array}{|c|} \hline 9 \\ \hline \end{array} & 1 \end{array}$$

从 $Ux = y$, 解得 $x = (\frac{1}{9}, \frac{1}{9}, \frac{1}{9}, \frac{1}{9})^T$.

平方根法和改进平方根法

Theorem

(对称矩阵的三角分解) 设 A 是 n 阶对称矩阵, 若 A 的各阶顺序主子式均不等于零, 则 A 可以唯一的分解为

$$A = LDL^T.$$

平方根法和改进平方根法

Theorem

(对称矩阵的三角分解) 设 A 是 n 阶对称矩阵, 若 A 的各阶顺序主子式均不等于零, 则 A 可以唯一的分解为

$$A = LDL^T.$$

Theorem

(对称正定矩阵的乔列斯基 (Cholesky) 分解) 设 A 是 n 阶对称正定矩阵, 则存在一个可逆的下三角阵 G , 使

$$A = GG^T.$$

当限定 G 的对角元为正时, 这种分解是唯一的.

平方根法和改进平方根法

由 G 是下三角阵($g_{ij} = 0, j > i$)及 A 的对称性, 故只考虑 A 的下三角部分的元素, 即 $i \geq j$ 的情况. 据 $A = GG^T$, 由矩阵乘法得

$$a_{ij} = \sum_{k=1}^n g_{ik}g_{jk} = \sum_{k=1}^{\min(i,j)} g_{ik}g_{jk} = \sum_{k=1}^j g_{ik}g_{jk} = \sum_{k=1}^{j-1} g_{ik}g_{jk} + g_{ij}g_{jj} .$$

平方根法和改进平方根法

由 G 是下三角阵($g_{ij} = 0, j > i$)及 A 的对称性, 故只考虑 A 的下三角部分的元素, 即 $i \geq j$ 的情况. 据 $A = GG^T$, 由矩阵乘法得

$$a_{ij} = \sum_{k=1}^n g_{ik}g_{jk} = \sum_{k=1}^{\min(i,j)} g_{ik}g_{jk} = \sum_{k=1}^j g_{ik}g_{jk} = \sum_{k=1}^{j-1} g_{ik}g_{jk} + g_{ij}g_{jj}.$$

当 $i = j$ 时, $a_{jj} = \sum_{k=1}^{j-1} g_{jk}^2 + g_{jj}^2.$

所以, $g_{jj} = (a_{jj} - \sum_{k=1}^{j-1} g_{jk}^2)^{\frac{1}{2}}. \quad j = 1, 2, \dots, n.$

平方根法和改进平方根法

由 G 是下三角阵($g_{ij} = 0, j > i$)及 A 的对称性, 故只考虑 A 的下三角部分的元素, 即 $i \geq j$ 的情况. 据 $A = GG^T$, 由矩阵乘法得

$$a_{ij} = \sum_{k=1}^n g_{ik}g_{jk} = \sum_{k=1}^{\min(i,j)} g_{ik}g_{jk} = \sum_{k=1}^j g_{ik}g_{jk} = \sum_{k=1}^{j-1} g_{ik}g_{jk} + g_{ij}g_{jj}.$$

当 $i = j$ 时, $a_{jj} = \sum_{k=1}^{j-1} g_{jk}^2 + g_{jj}^2.$

所以, $g_{jj} = (a_{jj} - \sum_{k=1}^{j-1} g_{jk}^2)^{\frac{1}{2}}. \quad j = 1, 2, \dots, n.$

当 $i > j$ 时,

$$g_{ij} = (a_{ij} - \sum_{k=1}^{j-1} g_{ik}g_{jk}) / g_{jj}, \quad j = 1, 2, \dots, n-1. \quad i = j+1, j+2, \dots, n.$$

当 $j = 1$ 时, $g_{i1} = a_{i1} / g_{11}, \quad i = 2, 3, \dots, n.$

平方根法和改进平方根法

$A = GG^T$ 分解的算法组织

```

$$g_{11} := \sqrt{a_{11}}$$

$$g_{i1} := a_{i1}/g_{11}, \quad i = 2, 3, \dots, n.$$

$$\text{for } j = 2 \text{ to } n - 1 \text{ do}$$

$$g_{jj} := (a_{jj} - \sum_{k=1}^{j-1} g_{jk}^2)^{\frac{1}{2}}$$

$$\text{for } i = j + 1 \text{ to } n \text{ do}$$

$$g_{ij} := (a_{ij} - \sum_{k=1}^{j-1} g_{ik}g_{jk})/g_{jj}$$

$$\text{end do}$$

$$\text{end do}$$

$$g_{nn} := (a_{nn} - \sum_{k=1}^{n-1} g_{nk}^2)^{\frac{1}{2}}$$

```

平方根法

用 $A = GG^T$ 分解求解方程组 $Ax = b$ 的方法称为平方根法.

$$Ax = b \implies GG^T x = b \implies \begin{cases} Gy = b \implies \text{解出 } y, \\ G^T x = y \implies \text{解出 } x. \end{cases}$$

由 $Gy = b$ 知

$$\begin{cases} g_{11}y_1 = b_1, \\ g_{i1}y_1 + g_{i2}y_2 + \cdots + g_{ii}y_i = b_i, \quad i = 2, 3, \cdots, n. \end{cases}$$

由此可得

$$\begin{cases} y_1 = b_1/g_{11}, \\ y_i = \left(b_i - \sum_{k=1}^{i-1} g_{ik}y_k \right) / g_{ii}, \quad i = 2, 3, \cdots, n. \end{cases}$$

然后从 $G^T x = y$, 解出 x .

平方根法

例 用平方根法求解方程组

$$\bar{A} = \begin{pmatrix} 9 & 18 & 9 & -27 & 1 \\ 18 & 45 & 0 & -45 & 2 \\ 9 & 0 & 126 & 9 & 16 \\ -27 & -45 & 9 & 135 & 8 \end{pmatrix}$$

平方根法

例 用平方根法求解方程组

$$\bar{A} = \begin{pmatrix} 9 & 18 & 9 & -27 & 1 \\ 18 & 45 & 0 & -45 & 2 \\ 9 & 0 & 126 & 9 & 16 \\ -27 & -45 & 9 & 135 & 8 \end{pmatrix}$$

解 $A = GG^T$, 其中

$$G = \begin{pmatrix} 3 & 0 & 0 & 0 \\ 6 & 3 & 0 & 0 \\ 3 & -6 & 9 & 0 \\ -9 & 3 & 6 & 3 \end{pmatrix}, y = \begin{pmatrix} \frac{1}{3} \\ 0 \\ \frac{5}{3} \\ \frac{1}{3} \end{pmatrix}.$$

因此,

$$\begin{cases} Gy = b \implies y = (\frac{1}{3}, 0, \frac{5}{3}, \frac{1}{3})^T. \\ G^T x = y \implies x = (\frac{1}{9}, \frac{1}{9}, \frac{1}{9}, \frac{1}{9})^T. \end{cases}$$

平方根法和改进平方根法

矩阵的Cholesky分解需要作 $\frac{1}{6}n^3 - \frac{1}{6}n$ 个乘除法与 n 个开方运算, 然后解两个三角方程组需要作 n^2 个乘除法. 故用平方根法求解 $Ax = b$. 共需要作 $\frac{1}{6}n^3 + n^2 - \frac{1}{6}n$ 个乘除法和 n 个开方运算, 但 n 个开方运算需要耗费较多的机器时间.

平方根法和改进平方根法

矩阵的Cholesky分解需要作 $\frac{1}{6}n^3 - \frac{1}{6}n$ 个乘除法与 n 个开方运算, 然后解两个三角方程组需要作 n^2 个乘除法. 故用平方根法求解 $Ax = b$. 共需要作 $\frac{1}{6}n^3 + n^2 - \frac{1}{6}n$ 个乘除法和 n 个开方运算, 但 n 个开方运算需要耗费较多的机器时间.

为了避免平方根法的开方运算, 对 A 作 $A = LDL^T$ 分解.

由 $A = LU = LDD^{-1}U = LDL^T$. 知 $L^T = D^{-1}U$. 根据杜里特尔分解式有

$$\begin{cases} d_i = a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 d_k, & i = 1, 2, \dots, n. \\ l_{ij} = (a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_k l_{jk}) / d_j, & j = 1, 2, \dots, n-1. \quad i = j+1, j+2, \dots \end{cases}$$

改进平方根法

用 $A = LDL^T$ 分解求解方程组 $Ax = b$, 称为改进平方根法.

$$Ax = b \implies LDL^T x = b \implies \begin{cases} Ly = b \implies \text{解出 } y, \\ L^T x = D^{-1}y \implies \text{解出 } x. \end{cases}$$

改进平方根法

用 $A = LDL^T$ 分解求解方程组 $Ax = b$, 称为改进平方根法.

$$Ax = b \implies LDL^T x = b \implies \begin{cases} Ly = b \implies \text{解出 } y, \\ L^T x = D^{-1}y \implies \text{解出 } x. \end{cases}$$

由 $Ly = b$ 得 $y_i = b_i - \sum_{k=1}^{i-1} l_{ik}y_k, \quad i = 2, 3, \dots, n.$

改进平方根法

用 $A = LDL^T$ 分解求解方程组 $Ax = b$, 称为改进平方根法.

$$Ax = b \implies LDL^T x = b \implies \begin{cases} Ly = b \implies \text{解出 } y, \\ L^T x = D^{-1}y \implies \text{解出 } x. \end{cases}$$

由 $Ly = b$ 得 $y_i = b_i - \sum_{k=1}^{i-1} l_{ik}y_k, \quad i = 2, 3, \dots, n.$

由 $L^T x = D^{-1}y$ 得

$$\begin{cases} x_n = y_n/d_n \\ x_i = \frac{y_i}{d_i} - \sum_{k=i+1}^n l_{ki}x_k, \quad i = n-1, n-2, \dots, 2, 1. \end{cases}$$

改进平方根法

用 $A = LDL^T$ 分解求解方程组 $Ax = b$, 称为改进平方根法.

$$Ax = b \implies LDL^T x = b \implies \begin{cases} Ly = b \implies \text{解出 } y, \\ L^T x = D^{-1}y \implies \text{解出 } x. \end{cases}$$

由 $Ly = b$ 得 $y_i = b_i - \sum_{k=1}^{i-1} l_{ik}y_k, \quad i = 2, 3, \dots, n.$

由 $L^T x = D^{-1}y$ 得

$$\begin{cases} x_n = y_n/d_n \\ x_i = \frac{y_i}{d_i} - \sum_{k=i+1}^n l_{ki}x_k, \quad i = n-1, n-2, \dots, 2, 1. \end{cases}$$

用改进平方根法解方程共用 $\frac{1}{6}n^3 + \frac{3}{2}n^2 - \frac{2}{3}n$ 个乘除法, 它比平方根法多了 $\frac{1}{2}n^2 - \frac{1}{2}n$ 个乘除法, 少了 n 个开方运算.

求解三对角方程组的追赶法

求解三对角方程组 $Ax = d$, 即

$$\begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}.$$

求解三对角方程组的追赶法

求解三对角方程组 $Ax = d$, 即

$$\begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}.$$

对于三对角矩阵 A , 则有如下形式的杜里特尔分解.

$$A = LU = \begin{pmatrix} 1 & & & & 0 \\ l_2 & 1 & & & \\ & \ddots & \ddots & & \\ 0 & & l_{n-1} & 1 & \\ & & & l_n & 1 \end{pmatrix} \begin{pmatrix} u_1 & c_1 & & & 0 \\ & u_2 & c_2 & & \\ & & \ddots & \ddots & \\ 0 & & & u_{n-1} & c_{n-1} \\ & & & & u_n \end{pmatrix}$$

求解三对角方程组的追赶法

用矩阵 $A = LU$ 分解求解三对角方程组称为追赶法.

$$\begin{cases} u_1 = b_1, \\ l_i = a_i / u_{i-1}, \quad i = 2, 3, \dots, n. \\ u_i = b_i - l_i c_{i-1}, \quad i = 2, 3, \dots, n. \end{cases}$$

即

$$\text{求解 } Ax = d \implies LUx = d \implies \begin{cases} Ly = d, \\ Ux = y. \end{cases}$$

求解三对角方程组的追赶法

用矩阵 $A = LU$ 分解求解三对角方程组称为**追赶法**.

$$\begin{cases} u_1 = b_1, \\ l_i = a_i / u_{i-1}, \quad i = 2, 3, \dots, n. \\ u_i = b_i - l_i c_{i-1}, \quad i = 2, 3, \dots, n. \end{cases}$$

即

$$\text{求解 } Ax = d \implies LUx = d \implies \begin{cases} Ly = d, \\ Ux = y. \end{cases}$$

由 $Ly = d$, 得

$$\begin{cases} y_1 = d_1, \\ y_i = d_i - l_i y_{i-1}, \quad i = 2, 3, \dots, n. \end{cases}$$

求解三对角方程组的追赶法

用矩阵 $A = LU$ 分解求解三对角方程组称为**追赶法**.

$$\begin{cases} u_1 = b_1, \\ l_i = a_i / u_{i-1}, \quad i = 2, 3, \dots, n. \\ u_i = b_i - l_i c_{i-1}, \quad i = 2, 3, \dots, n. \end{cases}$$

即

$$\text{求解 } Ax = d \implies LUx = d \implies \begin{cases} Ly = d, \\ Ux = y. \end{cases}$$

由 $Ly = d$, 得

$$\begin{cases} y_1 = d_1, \\ y_i = d_i - l_i y_{i-1}, \quad i = 2, 3, \dots, n. \end{cases}$$

由 $Ux = y$, 得

$$\begin{cases} x_n = y_n / u_n, \\ x_i = (y_i - c_i x_{i+1}) / u_i, \quad i = n-1, n-2, \dots, 1. \end{cases}$$

求解三对角方程组的追赶法

求解三对角方程 $Ax = d$ 的追赶法的算法组织.

```

$$\begin{aligned} &u_1 := b_1, \quad y_1 := d_1 \\ &\text{for } i = 2 \text{ to } n \text{ do} \\ &\quad l_i := a_i / u_{i-1} \\ &\quad u_i := b_i - l_i c_{i-1} \\ &\quad y_i := d_i - l_i y_{i-1} \\ &\text{end do} \\ &x_n := y_n / u_n \\ &\text{for } i = n - 1 \text{ to } 1 \text{ step } -1 \text{ do} \\ &\quad x_i := (y_i - c_i x_{i+1}) / u_i \\ &\text{end do} \end{aligned}$$

```

求解三对角方程组的追赶法

求解三对角方程 $Ax = d$ 的追赶法的算法组织.

```

 $u_1 := b_1, \quad y_1 := d_1$ 
for  $i = 2$  to  $n$  do
     $l_i := a_i / u_{i-1}$ 
     $u_i := b_i - l_i c_{i-1}$ 
     $y_i := d_i - l_i y_{i-1}$ 
end do
 $x_n := y_n / u_n$ 
for  $i = n - 1$  to  $1$  step  $-1$  do
     $x_i := (y_i - c_i x_{i+1}) / u_i$ 
end do
```

计算 l_i, u_i, y_i 的过程称为“追”的过程, 计算 x_i 的过程称为“赶”的过程. 追赶法的乘除法的运算次数仅为 $5n - 4$. 由于方程组系数矩阵 A 是严格对角占优阵, 保证了追赶法能顺利进行, 且计算过程稳定.

求解三对角方程组的追赶法

例 2.6 用追赶法求解线性方程组 $Ax = d$. 其中

$$A = \begin{pmatrix} 1 & 2 & 0 & 0 & 0 \\ 2 & 3 & 1 & 0 & 0 \\ 0 & -3 & 4 & 2 & 0 \\ 0 & 0 & 4 & 7 & 1 \\ 0 & 0 & 0 & -5 & 6 \end{pmatrix}, \quad d = \begin{pmatrix} 5 \\ 9 \\ 2 \\ 19 \\ -4 \end{pmatrix}.$$

求解三对角方程组的追赶法

例 2.6 用追赶法求解线性方程组 $Ax = d$. 其中

$$A = \begin{pmatrix} 1 & 2 & 0 & 0 & 0 \\ 2 & 3 & 1 & 0 & 0 \\ 0 & -3 & 4 & 2 & 0 \\ 0 & 0 & 4 & 7 & 1 \\ 0 & 0 & 0 & -5 & 6 \end{pmatrix}, \quad d = \begin{pmatrix} 5 \\ 9 \\ 2 \\ 19 \\ -4 \end{pmatrix}.$$

解 追赶法求解方程组有

$$L = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 & 0 \\ 0 & 3 & 1 & 0 & 0 \\ 0 & 0 & 4 & 1 & 0 \\ 0 & 0 & 0 & 5 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 1 & 2 & 0 & 0 & 0 \\ 0 & -1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 2 & 0 \\ 0 & 0 & 0 & -1 & 1 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}, \quad y = \begin{pmatrix} 5 \\ -1 \\ 5 \\ -1 \\ 1 \end{pmatrix}.$$

从 $Ly = d$ 解得 $y = (5, -1, 5, -1, 1)^T$, 从 $Ux = y$ 解得 $x = (1, 2, 1, 2, 1)^T$.

向量范数与矩阵范数

Definition

(向量范数) 设 $f(x) = \|x\|$ 是定义在 R^n 上的非负实值函数, 若 $\|x\|$ 满足以下三条:

- (1) $\|x\| \geq 0, \|x\| = 0 \Leftrightarrow x = 0$;
 - (2) $\forall \alpha \in R, \|\alpha x\| = |\alpha| \|x\|$;
 - (3) $\|x + y\| \leq \|x\| + \|y\|$; (三角不等式)
- 则称 $\|x\|$ 是 R^n 上的向量范数.

向量范数与矩阵范数

Definition

(向量范数) 设 $f(x) = \|x\|$ 是定义在 R^n 上的非负实值函数, 若 $\|x\|$ 满足以下三条:

- (1) $\|x\| \geq 0$, $\|x\| = 0 \Leftrightarrow x = 0$;
- (2) $\forall \alpha \in R$, $\|\alpha x\| = |\alpha| \|x\|$;
- (3) $\|x + y\| \leq \|x\| + \|y\|$; (三角不等式)

则称 $\|x\|$ 是 R^n 上的向量范数.

三种常用的向量范数:

$$\|x\|_1 = \sum_{i=1}^n |x_i| \quad (\text{向量的1-范数});$$

$$\|x\|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}} \quad (\text{向量的2-范数});$$

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i| \quad (\text{向量的}\infty\text{-范数}).$$

向量范数与矩阵范数

例如向量 $x = (2, -5, 3)^T$ 的三种范数分别为：

$$\|x\|_1 = 10, \quad \|x\|_2 = \sqrt{38}, \quad \|x\|_\infty = 5.$$

利用向量范数定义 x 的近似向量 \tilde{x} 的绝对误差与相对误差如下：

绝对误差： $\|\Delta x\| = \|x - \tilde{x}\|$ ，相对误差： $\frac{\|\Delta x\|}{\|x\|} = \frac{\|x - \tilde{x}\|}{\|x\|}$.

向量范数与矩阵范数

例如向量 $x = (2, -5, 3)^T$ 的三种范数分别为:

$$\|x\|_1 = 10, \quad \|x\|_2 = \sqrt{38}, \quad \|x\|_\infty = 5.$$

利用向量范数定义 x 的近似向量 \tilde{x} 的绝对误差与相对误差如下:

绝对误差: $\|\Delta x\| = \|x - \tilde{x}\|$, 相对误差: $\frac{\|\Delta x\|}{\|x\|} = \frac{\|x - \tilde{x}\|}{\|x\|}$.

Theorem

(向量范数的连续性) 设 $\|x\|$ 是 R^n 上任一种向量范数, 则 $\|x\|$ 是 x 的连续函数.

向量范数与矩阵范数

例如向量 $x = (2, -5, 3)^T$ 的三种范数分别为：

$$\|x\|_1 = 10, \quad \|x\|_2 = \sqrt{38}, \quad \|x\|_\infty = 5.$$

利用向量范数定义 x 的近似向量 \tilde{x} 的绝对误差与相对误差如下：

绝对误差： $\|\Delta x\| = \|x - \tilde{x}\|$ ，相对误差： $\frac{\|\Delta x\|}{\|x\|} = \frac{\|x - \tilde{x}\|}{\|x\|}$.

Theorem

(向量范数的连续性) 设 $\|x\|$ 是 R^n 上任一种向量范数，则 $\|x\|$ 是 x 的连续函数.

Theorem

(向量范数的等价性) 设 $\|x\|_p$ 和 $\|x\|_q$ 是 R^n 上任意两种向量范数，则存在常数 $c_1 > 0$, $c_2 > 0$ ，使得对任意的 $x \in R^n$ ，有

$$c_1 \|x\|_q \leq \|x\|_p \leq c_2 \|x\|_q.$$

向量范数与矩阵范数

常用的几个等价关系如下：

$$\left\{ \begin{array}{l} \|x\|_{\infty} \leq \|x\|_1 \leq n\|x\|_{\infty}; \\ \frac{1}{\sqrt{n}}\|x\|_1 \leq \|x\|_2 \leq \|x\|_1; \\ \frac{1}{\sqrt{n}}\|x\|_2 \leq \|x\|_{\infty} \leq \|x\|_2. \end{array} \right.$$

向量范数与矩阵范数

常用的几个等价关系如下：

$$\begin{cases} \|x\|_{\infty} \leq \|x\|_1 \leq n\|x\|_{\infty}; \\ \frac{1}{\sqrt{n}}\|x\|_1 \leq \|x\|_2 \leq \|x\|_1; \\ \frac{1}{\sqrt{n}}\|x\|_2 \leq \|x\|_{\infty} \leq \|x\|_2. \end{cases}$$

Definition

(矩阵范数) 设 $f(A) = \|A\|$ 是定义在 $R^{n \times n}$ 上的非负实值函数, 若 $\|A\|$ 满足以下四条:

- (1) $\|A\| \geq 0$, $\|A\| = 0 \Leftrightarrow A = O$;
- (2) $\forall \alpha \in R$, $\|\alpha A\| = |\alpha| \|A\|$;
- (3) $\|A + B\| \leq \|A\| + \|B\|$; (三角不等式)
- (4) $\|AB\| \leq \|A\| \|B\|$.

则称 $\|A\|$ 是 $R^{n \times n}$ 上的矩阵范数.

向量范数与矩阵范数

Definition

若矩阵范数 $\|A\|$ 与向量范数 $\|x\|$ 满足

$$\|Ax\| \leq \|A\| \|x\|, \quad \forall x \in R, A \in R^{n \times n}$$

则称矩阵范数 $\|A\|$ 与向量范数 $\|x\|$ 是相容的或协调的.

向量范数与矩阵范数

Definition

若矩阵范数 $\|A\|$ 与向量范数 $\|x\|$ 满足

$$\|Ax\| \leq \|A\| \|x\|, \quad \forall x \in R, A \in R^{n \times n}$$

则称矩阵范数 $\|A\|$ 与向量范数 $\|x\|$ 是相容的或协调的.

Theorem

(矩阵的算子范数) 设 $x \in R^n$, $A \in R^{n \times n}$, $\|x\|_p$ ($p = 1, 2, \infty$) 是给定的一种向量范数, 相应的定义一个矩阵的非负函数

$$\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = \max_{\|x\|_p=1} \|Ax\|_p.$$

则, $\|A\|_p$ 是一种矩阵范数, 称为 A 的算子范数, 且满足相容性条件 $\|Ax\|_p \leq \|A\|_p \|x\|_p$.

向量范数与矩阵范数

证明 (1) 显然, $\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p \geq 0$,

$$\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = 0 \Leftrightarrow \|Ax\|_p = 0, \forall x \neq 0 \Leftrightarrow Ax = 0, \forall x \neq 0$$

所以, $\|A\|_p = 0 \Leftrightarrow A = O$.

向量范数与矩阵范数

证明 (1) 显然, $\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p \geq 0$,

$$\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = 0 \Leftrightarrow \|Ax\|_p = 0, \forall x \neq 0 \Leftrightarrow Ax = 0, \forall x \neq 0$$

所以, $\|A\|_p = 0 \Leftrightarrow A = O$.

(2) $\forall \alpha \in R$,

$$\|\alpha A\|_p = \max_{\|x\|_p=1} \|\alpha Ax\|_p = |\alpha| \max_{\|x\|_p=1} \|Ax\|_p = |\alpha| \|A\|_p.$$

向量范数与矩阵范数

证明 (1) 显然, $\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p \geq 0$,

$$\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = 0 \Leftrightarrow \|Ax\|_p = 0, \forall x \neq 0 \Leftrightarrow Ax = 0, \forall x \neq 0$$

所以, $\|A\|_p = 0 \Leftrightarrow A = O$.

(2) $\forall \alpha \in R$,

$$\|\alpha A\|_p = \max_{\|x\|_p=1} \|\alpha Ax\|_p = |\alpha| \max_{\|x\|_p=1} \|Ax\|_p = |\alpha| \|A\|_p.$$

(3) 证三角不等式前先证相容性. 对于 $\forall x \neq 0$,

$$\frac{\|Ax\|_p}{\|x\|_p} \leq \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = \|A\|_p \Rightarrow \|Ax\|_p \leq \|A\|_p \|x\|_p.$$

向量范数与矩阵范数

利用相容性证三角不等式,

$$\begin{aligned}\|A + B\|_p &= \max_{\|x\|_p=1} \|(A + B)x\|_p = \max_{\|x\|_p=1} \|Ax + Bx\|_p \\ &\leq \max_{\|x\|_p=1} \|Ax\|_p + \max_{\|x\|_p=1} \|Bx\|_p \\ &\leq \max_{\|x\|_p=1} \|A\|_p \|x\|_p + \max_{\|x\|_p=1} \|B\|_p \|x\|_p = \|A\|_p + \|B\|_p .\end{aligned}$$

向量范数与矩阵范数

利用相容性证三角不等式,

$$\begin{aligned}\|A + B\|_p &= \max_{\|x\|_p=1} \|(A + B)x\|_p = \max_{\|x\|_p=1} \|Ax + Bx\|_p \\ &\leq \max_{\|x\|_p=1} \|Ax\|_p + \max_{\|x\|_p=1} \|Bx\|_p \\ &\leq \max_{\|x\|_p=1} \|A\|_p \|x\|_p + \max_{\|x\|_p=1} \|B\|_p \|x\|_p = \|A\|_p + \|B\|_p .\end{aligned}$$

(4) 由相容性有

$$\|ABx\|_p \leq \|A\|_p \|Bx\|_p \leq \|A\|_p \|B\|_p \|x\|_p .$$

$\forall x \neq 0$, 则

$$\frac{\|ABx\|_p}{\|x\|_p} \leq \|A\|_p \|B\|_p .$$

故

$$\|AB\|_p = \max_{x \neq 0} \frac{\|ABx\|_p}{\|x\|_p} \leq \|A\|_p \|B\|_p .$$

向量范数与矩阵范数

Theorem

设 $x \in R^n$, $A \in R^{n \times n}$, 按公式(2.3.3)确定的对应于向量的三种范数 $\|x\|_p$ ($p = 1, 2, \infty$) 的矩阵范数分别为

$$(1) \quad \|A\|_1 = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\} \quad (1\text{-范数或列范数});$$

$$(2) \quad \|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} \quad (2\text{-范数或谱范数});$$

$$(3) \quad \|A\|_{\infty} = \max_{1 \leq i \leq n} \left\{ \sum_{j=1}^n |a_{ij}| \right\} \quad (\infty \text{ 范数或行范数}).$$

其中 $\lambda_{\max}(A^T A)$ 表示矩阵 $A^T A$ 的最大特征值.

向量范数与矩阵范数

证明 (1) $A = (a_1, a_2, \dots, a_n)$, 则

$$\begin{aligned}\|Ax\|_1 &= \|x_1 a_1 + x_2 a_2 + \dots + x_n a_n\|_1 \leq |x_1| \|a_1\|_1 + \dots + |x_n| \|a_n\|_1 \\ &\leq (|x_1| + |x_2| + \dots + |x_n|) \max_{1 \leq j \leq n} \{\|a_j\|_1\} \\ &= \|x\|_1 \max_{1 \leq j \leq n} \{\|a_j\|_1\} .\end{aligned}$$

而

$$\|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 \leq \max_{1 \leq j \leq n} \{\|a_j\|_1\} = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\} .$$

向量范数与矩阵范数

证明 (1) $A = (a_1, a_2, \dots, a_n)$, 则

$$\begin{aligned}\|Ax\|_1 &= \|x_1 a_1 + x_2 a_2 + \dots + x_n a_n\|_1 \leq |x_1| \|a_1\|_1 + \dots + |x_n| \|a_n\|_1 \\ &\leq (|x_1| + |x_2| + \dots + |x_n|) \max_{1 \leq j \leq n} \{\|a_j\|_1\} \\ &= \|x\|_1 \max_{1 \leq j \leq n} \{\|a_j\|_1\}.\end{aligned}$$

而

$$\|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 \leq \max_{1 \leq j \leq n} \{\|a_j\|_1\} = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}.$$

下面说明存在一个向量 x , $\|x\|_1 = 1$, 使 $\|Ax\|_1 = \max_{1 \leq j \leq n} \{\|a_j\|_1\}$.

不妨假定 $\max_{1 \leq j \leq n} \{\|a_j\|_1\} = \|a_k\|_1$. 取 $x = e_k$, 显然 $\|e_k\|_1 = 1$, 且

$$\|Ae_k\|_1 = \|a_k\|_1 = \max_{1 \leq j \leq n} \{\|a_j\|_1\} = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}.$$

向量范数与矩阵范数

于是

$$\|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}.$$

向量范数与矩阵范数

于是

$$\|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}.$$

(2) 注意到 $A^T A$ 是实对称且至少是半正定矩阵, 由线性代数理论知 $A^T A$ 有完全的标准正交特征向量系 $u_i (i = 1, 2, \dots, n)$.

取 $u_i (i = 1, 2, \dots, n)$ 作为 R^n 的一组基底. $\forall x \in R, x \neq 0$, 则

$$x = \sum_{i=1}^n c_i u_i.$$

于是

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} = \frac{(Ax, Ax)}{(x, x)} = \frac{(A^T Ax, x)}{(x, x)} = \frac{\sum_{i=1}^n c_i^2 \lambda_i}{\sum_{i=1}^n c_i^2} \leq \lambda_1.$$

另一方面取 $x = u_1$, 则上式等号成立.

向量范数与矩阵范数

例 2.7 计算矩阵 $A = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix}$ 的三种范数.

向量范数与矩阵范数

例 2.7 计算矩阵 $A = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix}$ 的三种范数.

解

$$\|A\|_1 = \max\{4, 6\} = 6, \quad \|A\|_\infty = \max\{3, 7\} = 7.$$

向量范数与矩阵范数

例 2.7 计算矩阵 $A = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix}$ 的三种范数.

解

$$\|A\|_1 = \max\{4, 6\} = 6, \quad \|A\|_\infty = \max\{3, 7\} = 7.$$

以下求 $\|A\|_2$.

$$A^T A = \begin{pmatrix} 1 & 3 \\ -2 & 4 \end{pmatrix} \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix} = \begin{pmatrix} 10 & 10 \\ 10 & 20 \end{pmatrix},$$

$$|\lambda I - A^T A| = \begin{vmatrix} \lambda - 10 & -10 \\ -10 & \lambda - 20 \end{vmatrix} = \lambda^2 - 30\lambda + 100 = 0.$$

解特征方程, 得 $\lambda = 15 \pm 5\sqrt{5}$. 所以, $\lambda_{\max}(A^T A) = 15 + 5\sqrt{5}$.
故 $\|A\|_2 = \sqrt{15 + 5\sqrt{5}}$.

向量范数与矩阵范数

还有一种常用的矩阵范数是 F (Frobenius)范数:

$$\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}.$$

向量范数与矩阵范数

还有一种常用的矩阵范数是 F (Frobenius)范数:

$$\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}.$$

矩阵的 F 范数与向量的2-范数 $\|x\|_2$ 是相容的, 即

$$\|Ax\|_2 \leq \|A\|_F \|x\|_2.$$

事实上

$$\begin{aligned}\|Ax\|_2^2 &= \sum_{i=1}^n \left(\sum_{j=1}^n a_{ij} x_j \right)^2 \leq \sum_{i=1}^n \left(\sum_{j=1}^n a_{ij}^2 \sum_{k=1}^n x_k^2 \right) \\ &= \sum_{i=1}^n \sum_{j=1}^n a_{ij}^2 \cdot \sum_{k=1}^n x_k^2 = \|A\|_F^2 \|x\|_2^2.\end{aligned}$$

上式两边开方即得结论.

向量范数与矩阵范数

矩阵范数也具有其等价性. 即 $\|A\|_p, \|A\|_q$ 是 $R^{n \times n}$ 中任意两种矩阵范数, 则存在常数 $c_1 > 0, c_2 > 0$, 使

$$c_1 \|A\|_q \leq \|A\|_p \leq c_2 \|A\|_q, \quad \forall A \in R^{n \times n}$$

成立.

向量范数与矩阵范数

矩阵范数也具有其等价性. 即 $\|A\|_p$, $\|A\|_q$ 是 $R^{n \times n}$ 中任意两种矩阵范数, 则存在常数 $c_1 > 0$, $c_2 > 0$, 使

$$c_1 \|A\|_q \leq \|A\|_p \leq c_2 \|A\|_q, \quad \forall A \in R^{n \times n}$$

成立.

Definition

设 $A \in R^{n \times n}$, $\lambda_i (i = 1, 2, \dots, n)$ 是 A 的特征值, 则

$$\rho(A) = \max_{1 \leq i \leq n} \{|\lambda_i|\}$$

称为矩阵 A 的谱半径.

向量范数与矩阵范数

Theorem

设 $A \in R^{n \times n}$, 则 $\rho(A) \leq \|A\|$. 即谱半径不超过 A 的任一种范数.

向量范数与矩阵范数

Theorem

设 $A \in R^{n \times n}$, 则 $\rho(A) \leq \|A\|$. 即谱半径不超过 A 的任一种范数.

证明 设 λ 是 A 的任一特征值, x 是对应的特征向量, 则

$$Ax = \lambda x.$$

于是, $|\lambda| \|x\| = \|\lambda x\| = \|Ax\| \leq \|A\| \|x\|$. 注意到 $\|x\| \neq 0$, 则得

$$|\lambda| \leq \|A\|.$$

因而, $\rho(A) \leq \|A\|$.

向量范数与矩阵范数

Theorem

设 $\|B\| < 1$, 则 $I - B$ 是可逆矩阵, 且有

$$\|(I - B)^{-1}\| \leq \frac{1}{1 - \|B\|} .$$

向量范数与矩阵范数

Theorem

设 $\|B\| < 1$, 则 $I - B$ 是可逆矩阵, 且有

$$\|(I - B)^{-1}\| \leq \frac{1}{1 - \|B\|} .$$

证明 用反证法证 $I - B$ 可逆. 假定 $I - B$ 不可逆, 则方程组 $(I - B)x = 0$ 有非零解. 于是

$$\begin{aligned} 0 &= \|0\| = \|(I - B)x\| = \|x - Bx\| \geq \|x\| - \|Bx\| \geq \|x\| - \|B\| \|x\| \\ &= (1 - \|B\|)\|x\|. \end{aligned}$$

得到矛盾.

由 $I - B$ 可逆, 则有

$$\begin{aligned} 1 &= \|I\| = \|(I - B)(I - B)^{-1}\| = \|(I - B)^{-1} - B(I - B)^{-1}\| \\ &\geq \|(I - B)^{-1}\| - \|B(I - B)^{-1}\| \geq \|(I - B)^{-1}\| - \|B\| \|(I - B)^{-1}\| \\ &= (1 - \|B\|)\|(I - B)^{-1}\|. \end{aligned}$$

从而有 $\|(I - B)^{-1}\| \leq \frac{1}{1 - \|B\|} .$

舍入误差对解的影响

Theorem

设线性方程组 $Ax = b$ ($|A| \neq 0$, $b \neq 0$) 的系数矩阵 A 和右端项 b 有微小的扰动 ΔA 、 Δb , 扰动后的方程组为

$$(A - \Delta A)(x - \Delta x) = b - \Delta b.$$

当 $\|A^{-1}\| \|\Delta A\| < 1$ 时, 则方程组 $Ax = b$ 近似解 \tilde{x} 的相对误差估计式为

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right).$$

舍入误差对解的影响

Theorem

设线性方程组 $Ax = b$ ($|A| \neq 0$, $b \neq 0$) 的系数矩阵 A 和右端项 b 有微小的扰动 ΔA 、 Δb ，扰动后的方程组为

$$(A - \Delta A)(x - \Delta x) = b - \Delta b.$$

当 $\|A^{-1}\| \|\Delta A\| < 1$ 时，则方程组 $Ax = b$ 近似解 \tilde{x} 的相对误差估计式为

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right).$$

当 $\frac{\|\Delta A\|}{\|A\|}$ 较小时，近似解的相对误差 $\frac{\|\Delta x\|}{\|x\|}$ 约为 $\frac{\|\Delta A\|}{\|A\|}$ 与 $\frac{\|\Delta b\|}{\|b\|}$ 之和的 $\|A\| \|A^{-1}\|$ 倍. $\|A\| \|A^{-1}\|$ 越小，近似解的相对误差就越小.
 $\|A\| \|A^{-1}\|$ 反映了原始数据对解的影响.

舍入误差对解的影响

证明 由 $(A - \Delta A)(x - \Delta x) = b - \Delta b$ 和 $Ax = b$ 得

$$(A - \Delta A)\Delta x = \Delta b - \Delta Ax,$$

即

$$(I - A^{-1}\Delta A)\Delta x = A^{-1}(\Delta b - \Delta Ax).$$

由定理(2.3.6) 知 $I - A^{-1}\Delta A$ 可逆, 且

$$\|(I - A^{-1}\Delta A)^{-1}\| \leq \frac{1}{1 - \|A^{-1}\Delta A\|} \leq \frac{1}{1 - \|A^{-1}\| \|\Delta A\|}.$$

知

$$\Delta x = (I - A^{-1}\Delta A)^{-1}A^{-1}(\Delta b - \Delta Ax).$$

舍入误差对解的影响

两边取范数，有

$$\begin{aligned}\|\Delta x\| &\leq \|(I - A^{-1}\Delta A)^{-1}\| \|A^{-1}\| (\|\Delta b\| + \|\Delta A\| \|x\|) \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \|\Delta A\|} (\|\Delta b\| + \|\Delta A\| \|x\|) .\end{aligned}$$

上式两端除以 $\|x\|$ ，得

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \|\Delta A\|} \left(\frac{\|\Delta b\|}{\|x\|} + \|\Delta A\| \right)$$

舍入误差对解的影响

两边取范数，有

$$\begin{aligned}\|\Delta x\| &\leq \|(I - A^{-1}\Delta A)^{-1}\| \|A^{-1}\| (\|\Delta b\| + \|\Delta A\| \|x\|) \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \|\Delta A\|} (\|\Delta b\| + \|\Delta A\| \|x\|) .\end{aligned}$$

上式两端除以 $\|x\|$ ，得

$$\begin{aligned}\frac{\|\Delta x\|}{\|x\|} &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \|\Delta A\|} \left(\frac{\|\Delta b\|}{\|x\|} + \|\Delta A\| \right) \\ &= \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta b\|}{\|A\| \|x\|} + \frac{\|\Delta A\|}{\|A\|} \right) .\end{aligned}$$

注意到 $\|b\| = \|Ax\| \leq \|A\| \|x\|$ ，则得

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right) .$$

舍入误差对解的影响

Definition

设 A 是非奇异矩阵, 数

$$\text{Cond}(A) \triangleq \|A\| \|A^{-1}\|$$

称为矩阵 A 的条件数. 条件数与矩阵的范数有关, 也将条件数记为

$$\text{Cond}_p(A) \triangleq \|A\|_p \|A^{-1}\|_p \quad (p = 1, 2, \infty).$$

常用的矩阵条件数为

$$(1) \quad \text{Cond}_\infty(A) = \|A\|_\infty \|A^{-1}\|_\infty ;$$

$$(2) \quad \text{Cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}} .$$

当 A 是对称矩阵时 $\text{Cond}_2(A) = \frac{|\lambda_1|}{|\lambda_n|}$, 其中 λ_1, λ_n 分别是矩阵 A 的绝对值最大和绝对值最小的特征值.

舍入误差对解的影响

矩阵的条件数刻画了方程组的性态，条件数大的矩阵称为“病态”矩阵，相应的方程组称为“病态”方程组；条件数小的矩阵称为“良态”矩阵，相应的方程组称为“良态”方程组。

舍入误差对解的影响

矩阵的条件数刻画了方程组的性态，条件数大的矩阵称为“病态”矩阵，相应的方程组称为“病态”方程组；条件数小的矩阵称为“良态”矩阵，相应的方程组称为“良态”方程组。

例2.9 设有线性方程组

$$\begin{pmatrix} 1 & 10^5 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 10^5 \\ 2 \end{pmatrix}.$$

舍入误差对解的影响

矩阵的条件数刻画了方程组的性态，条件数大的矩阵称为“病态”矩阵，相应的方程组称为“病态”方程组；条件数小的矩阵称为“良态”矩阵，相应的方程组称为“良态”方程组。

例2.9 设有线性方程组

$$\begin{pmatrix} 1 & 10^5 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 10^5 \\ 2 \end{pmatrix}.$$

$$\text{则 } A^{-1} = \frac{1}{10^5 - 1} \begin{pmatrix} -1 & 10^5 \\ 1 & -1 \end{pmatrix},$$

$$\|A\|_{\infty} = 10^5 + 1, \quad \|A^{-1}\|_{\infty} = \frac{10^5 + 1}{10^5 - 1}, \quad \text{Cond}_{\infty}(A) > 10^5 \gg 1.$$

舍入误差对解的影响

例2.10 n 阶 Hilbert 阵, 随着矩阵 H_n 阶数 n 的增高, H_n 的条件数急剧增大, 此时方程组 $H_n x = b$ 是严重的病态方程组.

舍入误差对解的影响

例2.10 n 阶Hilbert阵, 随着矩阵 H_n 阶数 n 的增高, H_n 的条件数急剧增大, 此时方程组 $H_n x = b$ 是严重的病态方程组.

三阶Hilbert方程组为例说明其病态性.

$$\begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} \frac{11}{6} \\ \frac{13}{12} \\ \frac{47}{60} \end{pmatrix},$$

$$H_3^{-1} = \begin{pmatrix} 9 & -36 & 30 \\ -36 & 192 & -180 \\ 30 & -180 & 180 \end{pmatrix}.$$

$$\|H_3\|_{\infty} = \frac{11}{6}, \quad \|H_3^{-1}\|_{\infty} = 408, \quad \text{Cond}_{\infty}(H_3) = \|H_3\|_{\infty} \|H_3^{-1}\|_{\infty} = 748$$

若将方程组中的分数舍入到两位小数后求解, 则求得的近似解为 $\tilde{x} = (-6.22, 38.25, -33.65)^T$, 与真解 $x = (1, 1, 1)^T$ 相差甚远.

舍入误差对解的影响

例2.10 n 阶Hilbert阵, 随着矩阵 H_n 阶数 n 的增高, H_n 的条件数急剧增大, 此时方程组 $H_n x = b$ 是严重的病态方程组.

三阶Hilbert方程组为例说明其病态性.

$$\begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} \frac{11}{6} \\ \frac{13}{12} \\ \frac{47}{60} \end{pmatrix},$$

$$H_3^{-1} = \begin{pmatrix} 9 & -36 & 30 \\ -36 & 192 & -180 \\ 30 & -180 & 180 \end{pmatrix}.$$

$$\|H_3\|_{\infty} = \frac{11}{6}, \quad \|H_3^{-1}\|_{\infty} = 408, \quad \text{Cond}_{\infty}(H_3) = \|H_3\|_{\infty} \|H_3^{-1}\|_{\infty} = 748$$

若将方程组中的分数舍入到两位小数后求解, 则求得的近似解为 $\tilde{x} = (-6.22, 38.25, -33.65)^T$, 与真解 $x = (1, 1, 1)^T$ 相差甚远.

$$\text{Cond}_{\infty}(H_6) = 2.9 \times 10^7, \quad \text{Cond}_{\infty}(H_7) = 9.85 \times 10^8$$

舍入误差对解的影响

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；

舍入误差对解的影响

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；
- (2) 系数矩阵的元素数量级相差悬殊（如例2.9，例2.10）；

舍入误差对解的影响

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；
- (2) 系数矩阵的元素数量级相差悬殊（如例2.9，例2.10）；
- (3) 解对系数矩阵元素的变化比较敏感；

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；
- (2) 系数矩阵的元素数量级相差悬殊（如例2.9，例2.10）；
- (3) 解对系数矩阵元素的变化比较敏感；
- (4) 在主元素消去法求解过程中，出现量级很小的主元素；

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；
- (2) 系数矩阵的元素数量级相差悬殊（如例2.9，例2.10）；
- (3) 解对系数矩阵元素的变化比较敏感；
- (4) 在主元素消去法求解过程中，出现量级很小的主元素；
- (5) 求出的解与预期的解相差较大；

舍入误差对解的影响

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；
- (2) 系数矩阵的元素数量级相差悬殊（如例2.9，例2.10）；
- (3) 解对系数矩阵元素的变化比较敏感；
- (4) 在主元素消去法求解过程中，出现量级很小的主元素；
- (5) 求出的解与预期的解相差较大；

求解病态方程组应采取的措施:

- (1) 采用高精度（如双精度）计算，以减少舍入误差的影响；

舍入误差对解的影响

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；
- (2) 系数矩阵的元素数量级相差悬殊（如例2.9，例2.10）；
- (3) 解对系数矩阵元素的变化比较敏感；
- (4) 在主元素消去法求解过程中，出现量级很小的主元素；
- (5) 求出的解与预期的解相差较大；

求解病态方程组应采取的措施:

- (1) 采用高精度（如双精度）计算，以减少舍入误差的影响；
- (2) 采用稳定性好的算法（如全主元高斯消去法）；

舍入误差对解的影响

病态方程组的特征/判别

条件数计算很复杂，在实际中难以应用，往往具有下列现象之一的方程组可能是病态方程组.

- (1) 系数矩阵的行或列近似线性相关（如例2.8）；
- (2) 系数矩阵的元素数量级相差悬殊（如例2.9，例2.10）；
- (3) 解对系数矩阵元素的变化比较敏感；
- (4) 在主元素消去法求解过程中，出现量级很小的主元素；
- (5) 求出的解与预期的解相差较大；

求解病态方程组应采取的措施:

- (1) 采用高精度（如双精度）计算，以减少舍入误差的影响；
- (2) 采用稳定性好的算法（如全主元高斯消去法）；
- (3) 采取平衡措施；所谓平衡措施是将系数矩阵的各行除以该行绝对值最大的元素.

舍入误差对解的影响

例如对例2.9 的系数矩阵平衡后变

$$\text{为 } A = \begin{pmatrix} 10^{-5} & 1 \\ 1 & 1 \end{pmatrix}, A^{-1} = \frac{1}{1-10^{-5}} \begin{pmatrix} -1 & 1 \\ 1 & -10^{-5} \end{pmatrix},$$

$$\|A\|_{\infty} = 2, \|A^{-1}\|_{\infty} = \frac{2}{1-10^{-5}}, \text{Cond}_{\infty}(A) \approx 4.$$

舍入误差对解的影响

例如对例2.9 的系数矩阵平衡后变

$$\text{为 } A = \begin{pmatrix} 10^{-5} & 1 \\ 1 & 1 \end{pmatrix}, A^{-1} = \frac{1}{1-10^{-5}} \begin{pmatrix} -1 & 1 \\ 1 & -10^{-5} \end{pmatrix},$$

$$\|A\|_{\infty} = 2, \|A^{-1}\|_{\infty} = \frac{2}{1-10^{-5}}, \text{Cond}_{\infty}(A) \approx 4.$$

(4) 采用迭代改善技术；迭代改善技术适用于不是十分病态的线性方程组. 其实质是采用迭代的的思想，对近似解不断修正，使得近似解逐渐逼近方程组的准确解.

求修正量 Δx ，使得 $\tilde{x} + \Delta x$ 满足方程组 $Ax = b$ ，

即求解方程组 $A(\tilde{x} + \Delta \tilde{x}) = b$. $A\Delta x = r = b - A\tilde{x}$.

r 称为**残向量**，求得 Δx 后，重复以上过程，直到求得满足精度要求的近似解.

迭代改善技术

迭代改善技术计算过程如下：

- (1) 给定误差限 $\epsilon > 0$ ，将 A 进行三角分解 $A = LU$ ，求得方程组 $Ax = b$ 的一个近似解 $x^{(0)}$ ， $0 \Rightarrow k$ ；
- (2) 用双精度计算 $r^{(k)} = b - Ax^{(k)}$ ；
- (3) 解方程组 $Ly = r^{(k)}$ ， $U\Delta x = y$ ，设其解为 $\Delta x^{(k)}$ ；
- (4) 令 $x^{(k+1)} = x^{(k)} + \Delta x^{(k)}$ ；
- (5) 如果 $\|\Delta x^{(k)}\| \leq \epsilon$ ，或者 $\frac{\|\Delta x^{(k)}\|}{\|x^{(k+1)}\|} \leq \epsilon$ ，则取 $x^{(k+1)}$ 作为方程组 $Ax = b$ 的近似解，停；否则， $k+1 \Rightarrow k$ ，转步(2)。